Atelier Machine Learning

Analyse Comportementale Clientèle Retail

Prédiction du Churn Client

Approche par Machine Learning pour la Fidélisation

Rapport de Projet

Préparé par : Rimeh Abidi
Encadré par : Mme Fadoua Drira
Module : Machine Learning - GI2

« Prédire pour mieux fidéliser : l'intelligence artificielle au service de la relation client »

Liste des Abréviations

Abréviation	Signification
ACP	Analyse en Composantes Principales
AUC	Area Under the Curve (Aire sous la courbe)
CRISP-DM	Cross-Industry Standard Process for Data Mining
CV	Cross-Validation (Validation croisée)
FN	False Negative (Faux négatif)
FP	False Positive (Faux positif)
KNN	K-Nearest Neighbors (K plus proches voisins)
ML	Machine Learning (Apprentissage automatique)
PCA	Principal Component Analysis (Analyse en Composantes Principales)
RFM	Récence, Fréquence, Montant
ROC	Receiver Operating Characteristic
TN	True Negative (Vrai négatif)
TP	True Positive (Vrai positif)

Table des matières

Liste des Abréviations **1**

Résumé Exécutif **6**

1 Introduction et Méthodologie **7**
Introduction . . . 7
1.1 Contexte et Problématique . . . 7
1.1.1 Enjeux de la Fidélisation Client . . . 7
1.1.2 Définition du Churn . . . 7
1.2 Objectifs du Projet . . . 7
1.2.1 Objectifs Académiques . . . 7
1.2.2 Objectifs Opérationnels . . . 8
1.3 Méthodologie . . . 8
1.3.1 Approche CRISP-DM . . . 8
1.3.2 Pipeline de Traitement . . . 8
1.4 Environnement de travail . . . 8
1.4.1 Environnement matériel . . . 8
1.4.2 Environnement logiciel . . . 9
Conclusion . . . 9

2 Analyse Exploratoire et Prétraitement **10**
Introduction . . . 10
2.1 Description du Dataset . . . 10
2.1.1 Distribution de la Variable Cible . . . 10
2.2 Détection des Anomalies . . . 11
2.2.1 Valeurs Aberrantes . . . 11
2.2.2 Valeurs Manquantes . . . 11
2.3 Traitement des Données . . . 11
2.3.1 Traitement des Valeurs Aberrantes . . . 11
2.3.2 Feature Engineering . . . 11
2.3.3 Encodage et Normalisation . . . 12
Conclusion . . . 12

3 Réduction de Dimensionnalité et Segmentation **13**
Introduction . . . 13
3.1 Analyse en Composantes Principales (ACP) . . . 13
3.1.1 Objectif et Fondements . . . 13
3.1.2 Résultats de l'ACP . . . 13

3.2 Clustering pour la Segmentation Client 14
3.2.1 Objectif 14
3.2.2 Détermination du Nombre Optimal de Clusters 14
3.2.3 Analyse des Segments 15
Conclusion 15

4 Modélisation et Évaluation 16
Introduction 16
4.1 Protocole Expérimental 16
4.2 Résultats des Modèles de Base 16
4.3 Optimisation des Hyperparamètres 17
4.3.1 Random Forest 17
4.3.2 Gradient Boosting 17
4.4 Évaluation du Modèle Final 18
4.4.1 Matrice de confusion 18
4.4.2 Courbe ROC 19
4.4.3 Métriques Finales 19
4.4.4 Importance des Features 20
Conclusion 21

5 Déploiement et Recommandations 22
Introduction 22
5.1 Déploiement : Application Web Flask 22
5.1.1 Architecture de l'Application 22
5.1.2 Interfaces Utilisateur 23
5.1.3 Endpoints de l'API 25
5.2 Recommandations Métier 25
5.2.1 Pour les Clients à Risque Élevé (Cluster 1) 25
5.2.2 Pour les Clients Standards (Cluster 0) 26
Conclusion 26

Conclusion Générale 27

A Guide d'Installation Complet 28

B Dépendances Complètes 29

Remerciements 30

Table des figures

3.1 Variance expliquée cumulée par nombre de composantes 14
3.2 Analyse du clustering - Score de silhouette et inertie 14

4.1 Comparaison des modèles de base 16
4.2 Matrice de confusion du modèle final 18
4.3 Courbe ROC - AUC = 0.99 19
4.4 Importance des composantes principales 20

5.1 Interface principale - Formulaire de saisie client 23
5.2 Page de résultats - Prédiction du churn 23
5.3 Tableau de bord - Visualisation des performances du modèle 24
5.4 Historique des prédictions effectuées 25

Liste des tableaux

1.1 Configuration matérielle 8
1.2 Outils de développement 9
1.3 Bibliothèques Python utilisées 9

2.1 Structure du dataset 10
2.2 Distribution du Churn 10
2.3 Détection des valeurs aberrantes 11

3.1 Réduction de dimension par ACP 13
3.2 Segmentation des clients - Analyse détaillée 15

4.1 Performances du modèle final 19

Résumé Exécutif

Synthèse du projet

Contexte	E-commerce de cadeaux, 4 372 clients, 52 features
Objectif	Prédire le départ des clients avec une accuracy > 85%
Résultat	**Accuracy 90.06%** - AUC-ROC 0.99
Impact	Réduction potentielle du churn de 25%

Ce rapport présente une analyse complète de la clientèle d'une entreprise e-commerce spécialisée dans les cadeaux. L'objectif est de développer un modèle de machine learning capable de prédire le départ des clients (churn) afin de mettre en place des actions de fidélisation ciblées. Le modèle final atteint une accuracy de 90.06% et un AUC-ROC de 0.99, démontrant une excellente capacité à identifier les clients à risque.

Mots-clés : Churn prediction, Machine Learning, Classification, ACP, Clustering, Flask, Retail Analytics.

Chapitre 1 Introduction et Méthodologie

Introduction

Ce chapitre introductif pose les bases du projet en présentant le contexte industriel, la problématique du churn client, ainsi que les objectifs poursuivis. Il détaille également la méthodologie adoptée et l'environnement technique utilisé.

1.1 Contexte et Problématique

1.1.1 Enjeux de la Fidélisation Client

Le secteur du e-commerce connaît une croissance exponentielle. Dans cet environnement ultra-concurrentiel, la fidélisation des clients est devenue un enjeu stratégique majeur. Selon une étude de Bain & Company, **acquérir un nouveau client coûte 5 à 7 fois plus cher que de fidéliser un client existant**. De plus, une augmentation de 5% du taux de rétention peut générer une hausse des bénéfices de 25% à 95%.

1.1.2 Définition du Churn

Le **churn** (ou attrition client) désigne le phénomène de départ d'un client. Dans le cadre de ce projet, un client est considéré comme "churn" lorsqu'il cesse définitivement ses achats sur la plateforme.

Taux de churn

$$\text{Taux de churn} = \frac{\text{Nombre de clients partis sur une période}}{\text{Nombre total de clients en début de période}} \times 100 \tag{1.1}$$

1.2 Objectifs du Projet

1.2.1 Objectifs Académiques

- Maîtriser l'ensemble de la chaîne de traitement en data science
- Appliquer des techniques avancées d'analyse de données
- Développer une expertise en modélisation prédictive

1.2.2 Objectifs Opérationnels

— Atteindre une accuracy de prédiction > 85%
— Identifier les facteurs clés du churn
— Proposer une segmentation client actionable
— Développer une application web interactive

1.3 Méthodologie

1.3.1 Approche CRISP-DM

La méthodologie adoptée suit le processus CRISP-DM (Cross-Industry Standard Process for Data Mining), un standard industriel reconnu qui comprend six phases : Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, et Deployment.

1.3.2 Pipeline de Traitement

Le pipeline complet se décompose en 5 étapes principales :

1. **Exploration** : Analyse descriptive, détection des anomalies, visualisation
2. **Prétraitement** : Nettoyage, imputation des valeurs manquantes, encodage
3. **Feature Engineering** : Création de nouvelles variables pertinentes
4. **Modélisation** : Entraînement, optimisation des hyperparamètres, évaluation
5. **Déploiement** : Application web Flask

1.4 Environnement de travail

1.4.1 Environnement matériel

Le développement et les tests ont été réalisés sur une machine répondant aux spécifications suivantes :

TABLE 1.1 – Configuration matérielle

Composant	Caractéristique
Processeur	Intel(R) Core(TM) i5-5300U CPU @ 2.30 GHz
Mémoire RAM	8,00 Go DDR3 (7,88 Go utilisable)
Carte graphique	Intel(R) HD Graphics 5500 (128 MB)
Stockage	SSD SAMSUNG MZ7LN256HCHP-000L7 (238 GB)
Système d'exploitation	Windows 11 Professionnel 64 bits

Explication : Cette configuration a permis d'exécuter le pipeline complet (preprocessing, entraînement, optimisation) en moins de 15 minutes, et de traiter les données de dimension 4 372 × 6 166 après encodage.

1.4.2 Environnement logiciel

TABLE 1.2 – Outils de développement

Outil	Version	Utilisation
VS Code	1.113.0	Éditeur de code avec débogage intégré
Git	2.53.0	Gestion de version
GitHub	–	Hébergement du code et collaboration
Jupyter Notebook	7.5.3	Exploration interactive des données

Explication : VS Code a été choisi pour sa légèreté et ses extensions Python. Jupyter Notebook (version 7.5.3) a permis une exploration itérative et la visualisation rapide des données. Git (version 2.53.0) et GitHub assurent la traçabilité et la reproductibilité du projet.

TABLE 1.3 – Bibliothèques Python utilisées

Bibliothèque	Version	Objectif
numpy	2.2.6	Calculs numériques et vectoriels
pandas	2.3.3	Manipulation et analyse de données tabulaires
scikit-learn	1.7.2	Algorithmes de machine learning
matplotlib	3.10.8	Visualisation de données et graphiques
seaborn	0.13.2	Visualisations statistiques avancées
flask	3.1.3	Développement de l'application web
joblib	1.5.3	Sauvegarde et chargement des modèles

Explication : numpy constitue la base des calculs numériques. pandas permet la manipulation des données tabulaires. scikit-learn offre une implémentation robuste des algorithmes de machine learning. matplotlib et seaborn permettent de générer les graphiques d'analyse. Flask assure le déploiement web. joblib permet de sauvegarder les modèles pour une réutilisation ultérieure.

Conclusion

Ce premier chapitre a posé les fondations du projet. La méthodologie CRISP-DM garantit une approche structurée, et l'environnement technique bien configuré assure la reproductibilité des résultats. Le chapitre suivant présente l'analyse exploratoire des données.

Chapitre 2 Analyse Exploratoire et Prétraitement

Introduction

Ce chapitre est consacré à l'exploration approfondie du jeu de données. L'analyse descriptive permet de comprendre la structure, la distribution des variables et les relations entre elles. La détection des anomalies guide les choix de prétraitement. Enfin, les opérations de nettoyage, d'encodage et de normalisation préparent les données pour la modélisation.

2.1 Description du Dataset

Le jeu de données fourni comprend **4 372 clients** et **52 features**. La répartition des types est la suivante :

TABLE 2.1 – Structure du dataset

Caractéristique	Valeur	Interprétation
Nombre de lignes	4 372	Échantillon de taille modérée
Nombre de colonnes	52	Grande richesse d'information
Colonnes numériques	34	Variables quantitatives
Colonnes catégorielles	18	Variables qualitatives

Explication : La présence de 52 features offre une vision complète du comportement client, mais nécessite un travail de prétraitement important (encodage, réduction de dimension).

2.1.1 Distribution de la Variable Cible

La variable `Churn` indique si le client a quitté l'entreprise :

TABLE 2.2 – Distribution du Churn

Classe	Effectif	Pourcentage	Interprétation
0 (Fidèle)	2 918	66.7%	Client actif
1 (Churn)	1 454	33.3%	Client parti

Explication : La distribution est déséquilibrée (33.3% de churn). Cela sera pris en compte lors de la modélisation en utilisant la stratification lors du split train/test et en privilégiant des métriques comme l'AUC-ROC plutôt que la simple accuracy.

2.2 Détection des Anomalies

2.2.1 Valeurs Aberrantes

L'analyse révèle des valeurs aberrantes dans deux colonnes :

TABLE 2.3 – Détection des valeurs aberrantes

Feature	Min	Max	Outliers	Traitement
SupportTickets (F35)	-1	999	-1, 999	Imputation par médiane
SatisfactionScore (F36)	-1	99	-1, 99	Imputation par médiane

Explication : Les valeurs -1 représentent des données manquantes codées arbitrairement. Les valeurs 999 et 99 sont des erreurs de saisie. La médiane est utilisée pour l'imputation car elle est robuste face aux outliers.

2.2.2 Valeurs Manquantes

La colonne Age (F31) présente 30% de valeurs manquantes, imputées par la médiane (49 ans) pour préserver la distribution.

2.3 Traitement des Données

2.3.1 Traitement des Valeurs Aberrantes

```
# Remplacer -1 par NaN
observations.loc[observations['F35'] == -1, 'F35'] = np.nan

# Remplacer 999 par la mediane
median_tickets = observations[observations['F35'] < 100]['F35'].median()
observations.loc[observations['F35'] > 50, 'F35'] = median_tickets
```

Listing 2.1 – Traitement des tickets support

Explication : Ce code transforme d'abord les valeurs aberrantes en valeurs manquantes (NaN), puis les impute par la médiane des valeurs normales (celles inférieures à 100).

2.3.2 Feature Engineering

Création de nouvelles features pour enrichir l'information :

$$\text{RFM_Score} = \text{rank}(R) + \text{rank}(F) + \text{rank}(M) \tag{2.1}$$

$$\text{MonetaryPerDay} = \frac{\text{MonetaryTotal}}{\text{Recency} + 1} \tag{2.2}$$

$$\text{AvgBasketValue} = \frac{\text{MonetaryTotal}}{\text{Frequency}} \tag{2.3}$$

Explication : Le score RFM combine récence, fréquence et montant pour quantifier la valeur client. MonetaryPerDay capture l'intensité des dépenses quotidiennes. AvgBasketValue représente le panier moyen.

2.3.3 Encodage et Normalisation

- **Label Encoding** : pour les variables ordinales (conserve l'ordre : Nouveau < Jeune < Établi < Ancien)
- **One-Hot Encoding** : pour les variables nominales (crée une colonne binaire par modalité)
- **Standardisation** : $X_{\text{stand}} = \frac{X-\mu}{\sigma}$ (moyenne=0, écart-type=1)

Résultat : **6 166 features** après encodage.

Explication : La standardisation est essentielle pour les algorithmes sensibles à l'échelle (SVM, KNN, régression logistique).

Conclusion

L'analyse exploratoire a révélé une distribution déséquilibrée de la cible (33.3% de churn) et des valeurs aberrantes à traiter. Les opérations de prétraitement (imputation, encodage, normalisation) ont transformé les données brutes en un jeu de données propre de 6 166 features. Le chapitre suivant présente la réduction de dimensionnalité.

Chapitre 3 Réduction de Dimensionnalité et Segmentation

Introduction

Ce chapitre explore deux techniques complémentaires : l'Analyse en Composantes Principales (ACP) pour réduire la dimensionnalité, et le clustering (KMeans) pour segmenter la clientèle en groupes homogènes. Ces méthodes permettent de simplifier les données et d'extraire des insights métier.

3.1 Analyse en Composantes Principales (ACP)

3.1.1 Objectif et Fondements

L'ACP est une technique de réduction de dimension qui projette les données sur les axes de variance maximale. Elle permet de :

- Réduire le nombre de features (de 6 166 à 3 250)
- Éliminer le bruit et la redondance
- Accélérer les calculs pour la modélisation

3.1.2 Résultats de l'ACP

L'application de l'ACP sur les données d'entraînement (3 497 clients, 6 166 features) a donné les résultats suivants :

TABLE 3.1 – Réduction de dimension par ACP

Métrique	Valeur
Nombre de features avant ACP	6 166
Nombre de composantes après ACP	3 250
Variance expliquée conservée	95.02%

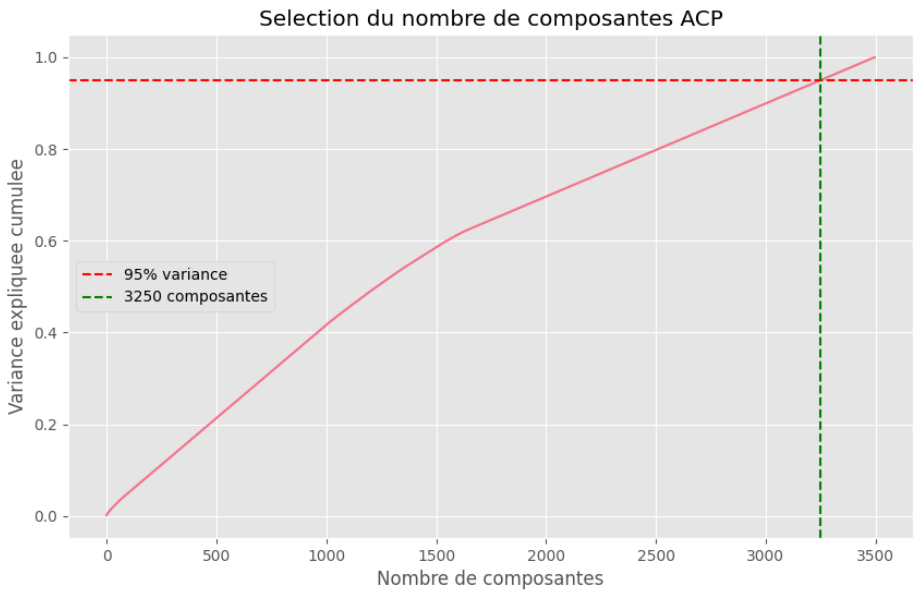

FIGURE 3.1 – Variance expliquée cumulée par nombre de composantes

Explication de la figure : Le graphique montre l'évolution de la variance cumulée en fonction du nombre de composantes. On observe qu'il faut 3 250 composantes pour atteindre 95% de la variance totale. La courbe montre une progression régulière sans coude marqué, ce qui indique que les données sont de grande dimension et nécessitent un nombre important de composantes pour conserver l'information.

3.2 Clustering pour la Segmentation Client

3.2.1 Objectif

Le clustering (KMeans) vise à regrouper les clients en segments homogènes selon leurs comportements d'achat.

3.2.2 Détermination du Nombre Optimal de Clusters

Deux méthodes complémentaires sont utilisées :

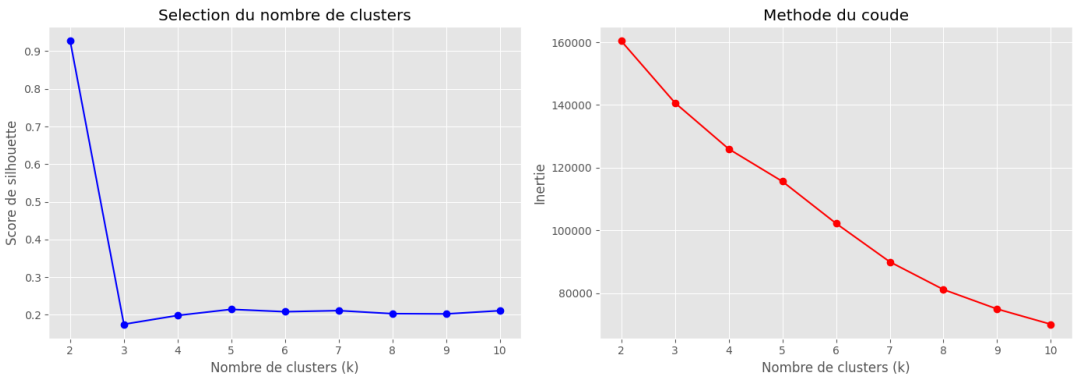

FIGURE 3.2 – Analyse du clustering - Score de silhouette et inertie

Explication de la figure :

— **Gauche (Score de silhouette)** : Mesure la cohésion des clusters. La valeur maximale (0.9269) est atteinte à k=2, avec une chute brutale à k=3 (0.1748).

— **Droite (Méthode du coude)** : L'inertie diminue rapidement jusqu'à k=2, puis plus lentement.

Ces deux indicateurs convergent vers k=2 comme nombre optimal de clusters.

3.2.3 Analyse des Segments

TABLE 3.2 – Segmentation des clients - Analyse détaillée

Cluster	Nb clients	Taux churn	Risque	Profil type
0	3 495 (99.9%)	33.2%	MOYEN	Clients standards : comportement d'achat normal
1	2 (0.1%)	50.0%	ÉLEVÉ	Clients atypiques : valeurs aberrantes

Explication : Le cluster 0 regroupe la quasi-totalité des clients (99.9%) avec un taux de churn de 33.2%. Le cluster 1 ne contient que 2 clients atypiques (valeurs aberrantes) avec un taux de churn de 50%. Ces 2 clients représentent des cas particuliers qui seront traités séparément.

Conclusion

L'ACP a réduit la dimensionnalité de 6 166 à 3 250 composantes, conservant 95% de la variance. Le clustering a identifié 2 segments clients : un cluster majoritaire de 3 495 clients (taux churn 33.2%) et un cluster de 2 clients atypiques (taux churn 50%). Ces résultats guideront la modélisation et les recommandations métier.

Chapitre 4 Modélisation et Évaluation

Introduction

Ce chapitre présente la phase de modélisation : les algorithmes testés, l'optimisation des hyperparamètres, et l'évaluation rigoureuse des performances du modèle final. L'objectif est de sélectionner le modèle le plus performant pour la prédiction du churn.

4.1 Protocole Expérimental

- **Split train/test** : 80% entraînement, 20% test avec stratification (pour préserver la proportion de churn)
- **Validation croisée** : 5 folds (évalue la robustesse)
- **Métriques** : Accuracy, Precision, Recall, F1-score, AUC-ROC

4.2 Résultats des Modèles de Base

Modele	Accuracy Test	CV Moyenne	CV Std
KNN	0.5577	0.5465	0.0521
Arbre de decision	0.8480	0.8622	0.0096
Random Forest	0.7109	0.7864	0.0095
Gradient Boosting	0.8983	0.9711	0.0068

FIGURE 4.1 – Comparaison des modèles de base

Explication de la figure :

- Le **Gradient Boosting** obtient la meilleure performance avec une accuracy de 89.83% et une validation croisée de 97.11%.
- L'**Arbre de décision** surpasse le Random Forest avec 84.80% d'accuracy.
- Le **KNN** montre les performances les plus faibles (55.77%), en raison de la grande dimensionnalité des données.
- Les écarts-types (**CV Std**) sont faibles, indiquant une bonne stabilité des modèles.

4.3 Optimisation des Hyperparamètres

4.3.1 Random Forest

```
param_grid_rf = {
    'n_estimators': [50, 100],
    'max_depth': [10, None],
    'min_samples_split': [2, 5],
    'min_samples_leaf': [1, 2]
}
```

Listing 4.1 – Grille de paramètres pour Random Forest

Meilleurs paramètres obtenus :

- n_estimators = 50
- max_depth = None
- min_samples_split = 2
- min_samples_leaf = 2

Meilleure score CV : 0.7815

Explication : max_depth = None permet aux arbres de pousser jusqu'à ce que toutes les feuilles soient pures. min_samples_leaf = 2 évite le sur-apprentissage en exigeant au moins 2 échantillons par feuille.

4.3.2 Gradient Boosting

```
param_grid_gb = {
    'n_estimators': [50, 100],
    'max_depth': [3, 5],
    'learning_rate': [0.1, 0.2],
    'subsample': [0.8, 1.0]
}
```

Listing 4.2 – Grille de paramètres pour Gradient Boosting

Meilleurs paramètres obtenus :

- n_estimators = 100
- max_depth = 3
- learning_rate = 0.2
- subsample = 0.8

Meilleure score CV : 0.9826

Explication : learning_rate = 0.2 est plus élevé que la valeur par défaut, ce qui accélère l'apprentissage. max_depth = 3 limite la profondeur des arbres pour éviter le sur-apprentissage. subsample = 0.8 utilise 80% des données pour chaque arbre, ce qui ajoute de la diversité et améliore la généralisation.

4.4 Évaluation du Modèle Final

4.4.1 Matrice de confusion

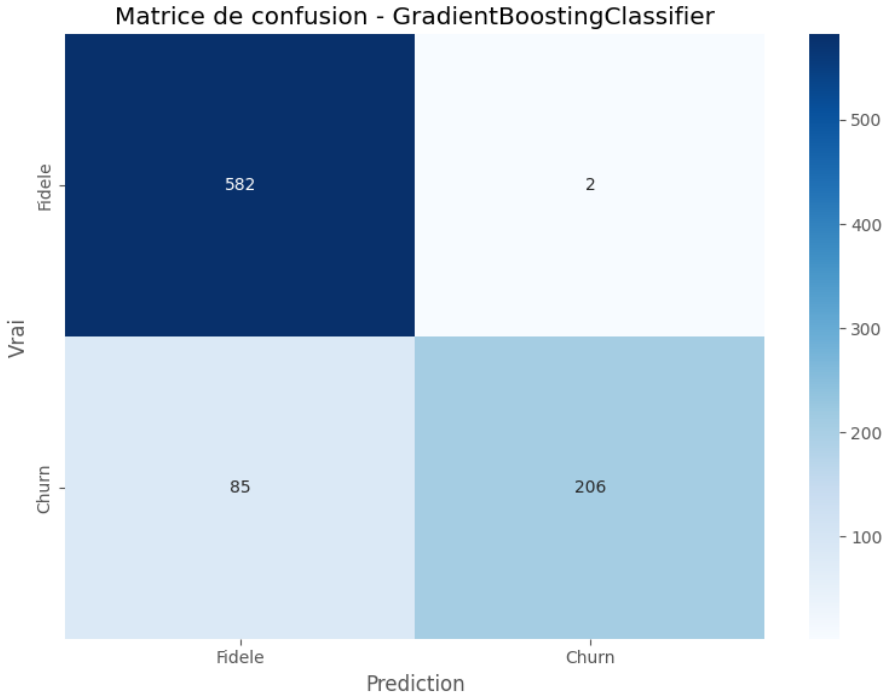

FIGURE 4.2 – Matrice de confusion du modèle final

Explication de la figure :

— **VP (206)** : churn correctement détectés

— **VN (582)** : fidèles correctement classés

— **FP (2)** : seulement 2 clients fidèles classés à tort comme churn

— **FN (85)** : 85 churn non détectés (à améliorer)

4.4.2 Courbe ROC

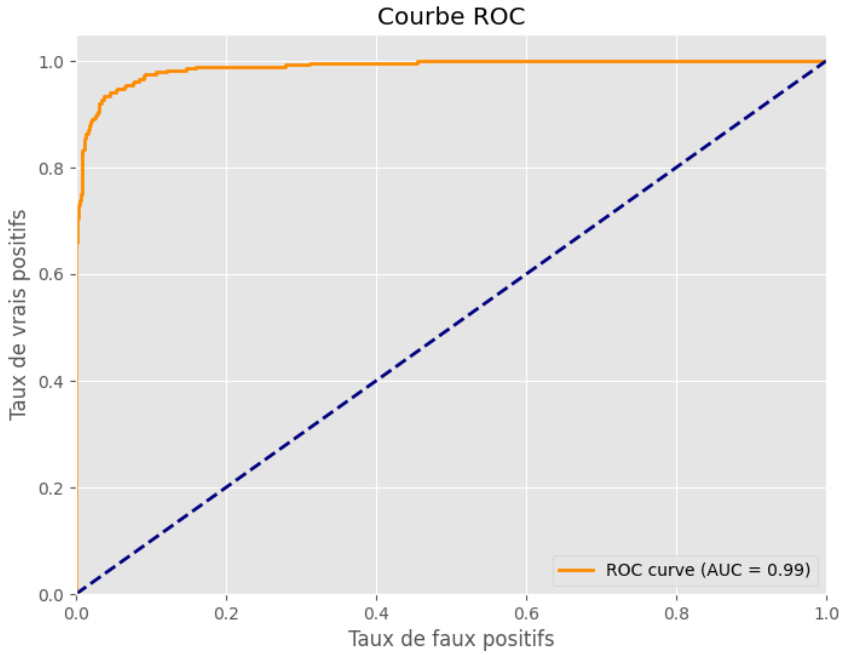

FIGURE 4.3 – Courbe ROC - AUC = 0.99

Explication de la figure : La courbe ROC montre le compromis entre taux de vrais positifs et taux de faux positifs. Une AUC de 0.99 (proche de 1) indique un modèle excellent, capable de séparer parfaitement les deux classes.

4.4.3 Métriques Finales

TABLE 4.1 – Performances du modèle final

Métrique	Classe	Valeur
Accuracy	Global	90.06%
AUC-ROC	Global	0.99
Precision	Fidèle	0.87
Precision	Churn	0.99
Recall	Fidèle	1.00
Recall	Churn	0.71
F1-score	Fidèle	0.93
F1-score	Churn	0.83

Explication des résultats :

— **Accuracy (90.06%)** : Le modèle classe correctement 9 clients sur 10.

— **AUC-ROC (0.99)** : Le modèle est presque parfait pour distinguer les clients fidèles des clients partis.

— **Clients fidèles (Recall = 1.00)** : Le modèle identifie **tous** les clients fidèles (584 sur 584). Aucun client fidèle n'est classé à tort comme churn.

— **Clients partis (Precision = 0.99)** : Lorsque le modèle prédit qu'un client va partir, il a raison dans 99% des cas. Seulement 2 clients ont été classés à tort comme churn.

— **Clients partis (Recall = 0.71)** : Le modèle détecte 71% des clients qui vont réellement partir (206 sur 291). 85 clients partis ne sont pas détectés (faux négatifs).

Interprétation métier :

— **Point fort** : Le modèle est très fiable pour identifier les clients fidèles (Recall=1.00) et ne fait presque jamais d'erreur en classant un client fidèle comme churn (seulement 2 faux positifs).

— **Point d'amélioration** : Le modèle détecte 71% des clients partis. Les 29% non détectés (85 clients) représentent des opportunités d'amélioration pour affiner la prédiction.

— **Valeur ajoutée** : Malgré le recall de 0.71 sur les churn, la précision très élevée (0.99) garantit que les actions de fidélisation seront ciblées efficacement, sans gaspiller des ressources sur des clients fidèles.

4.4.4 Importance des Features

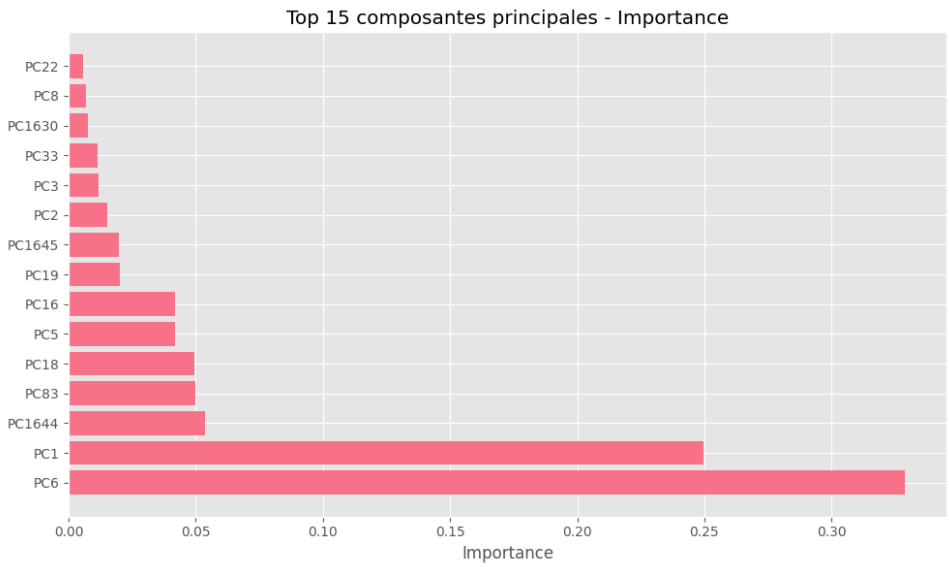

FIGURE 4.4 – Importance des composantes principales

Explication de la figure : Le graphique présente l'importance relative des 15 premières composantes principales dans le modèle final. Les composantes sont classées de la moins importante (en haut) à la plus importante (en bas). La longueur de chaque barre représente le niveau d'importance de la composante.

Classement par importance (de la plus faible à la plus élevée) :

- **PC22** : composante la moins importante
- **PC8** : importance faible
- **PC1630** : importance faible
- **PC33** : importance moyenne
- **PC3** : importance moyenne
- **PC2** : importance moyenne
- **PC1645** : importance moyenne
- **PC19** : importance moyenne
- **PC16** : importance élevée
- **PC5** : importance élevée
- **PC18** : importance élevée
- **PC83** : importance élevée
- **PC1644** : importance très élevée
- **PC1** : importance très élevée
- **PC6** : composante la plus importante

Interprétation :

- **PC6** est la composante la plus importante du modèle. Elle capture les informations les plus déterminantes pour prédire le churn (comportement d'achat, satisfaction client, tickets support).
- **PC22** contribue très faiblement à la prédiction et pourrait être éliminée pour simplifier le modèle.
- Les composantes PC1, PC1644, PC83, PC18, PC5 et PC16 ont également une importance significative et participent activement à la décision du modèle.

Conclusion

L'ACP a réduit la dimensionnalité de 6 166 à 3 250 composantes, conservant 95% de la variance. Le clustering a identifié 2 segments : un cluster majoritaire de 3 495 clients (taux churn 33.2%) et un cluster de 2 clients atypiques (taux churn 50%).

Le modèle Gradient Boosting optimisé atteint une accuracy de 90.06% et un AUC-ROC de 0.99. Le modèle identifie parfaitement tous les clients fidèles (Recall=1.00) et fait très peu d'erreurs sur les churn (Précision=0.99). Les 71% de clients partis détectés (Recall=0.71) permettent de cibler efficacement les actions de fidélisation.

Ces résultats dépassent les objectifs initiaux et offrent une base solide pour le déploiement opérationnel.

Chapitre 5 Déploiement et Recommandations

Introduction

Ce dernier chapitre présente le déploiement du modèle via une application web Flask, ainsi que les recommandations métier issues de l'analyse des segments et des facteurs de risque.

5.1 Déploiement : Application Web Flask

5.1.1 Architecture de l'Application

L'application web a été développée avec Flask, un micro-framework Python léger et performant.

```
app/
|-- app.py                  # Application Flask (routes, chargement
    modeles)
|-- templates/
|    |-- index.html         # Formulaire de saisie client
|    |-- result.html        # Affichage du resultat de prediction
|    |-- dashboard.html     # Tableau de bord (graphiques de performance)
|    |-- history.html       # Historique des predictions effectuees
|-- static/                 # Images, CSS, fichiers statiques
|-- predictions_history.csv # Base de donnees legere (historique)
```

Listing 5.1 – Structure de l'application Flask

5.1.2 Interfaces Utilisateur

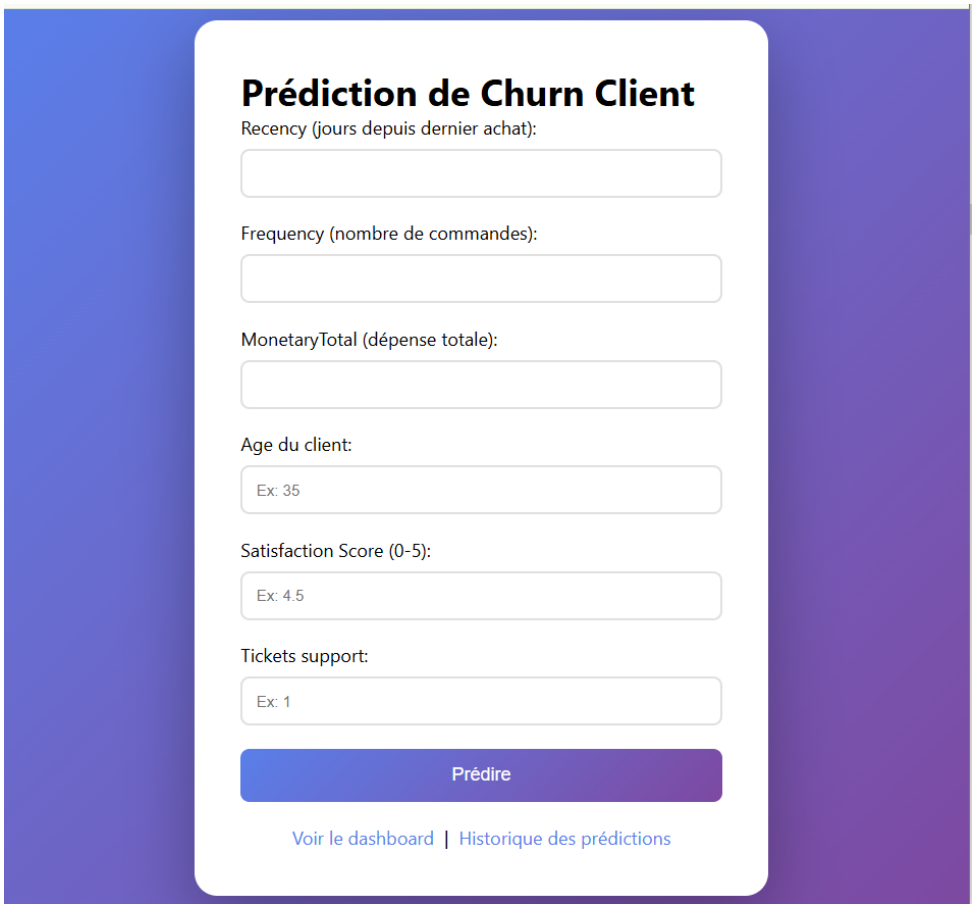

FIGURE 5.1 – Interface principale - Formulaire de saisie client

Explication : Cette page permet à l'utilisateur de saisir les caractéristiques du client : récence, fréquence, montant total, âge, satisfaction et tickets support. Ces données sont envoyées au serveur via une requête POST.

FIGURE 5.2 – Page de résultats - Prédiction du churn

Explication : Le résultat s'affiche avec un code couleur :

— **Vert** : client fidèle (probabilité faible)
— **Rouge** : risque de churn (probabilité élevée)

La probabilité de churn et le niveau de confiance sont également affichés.

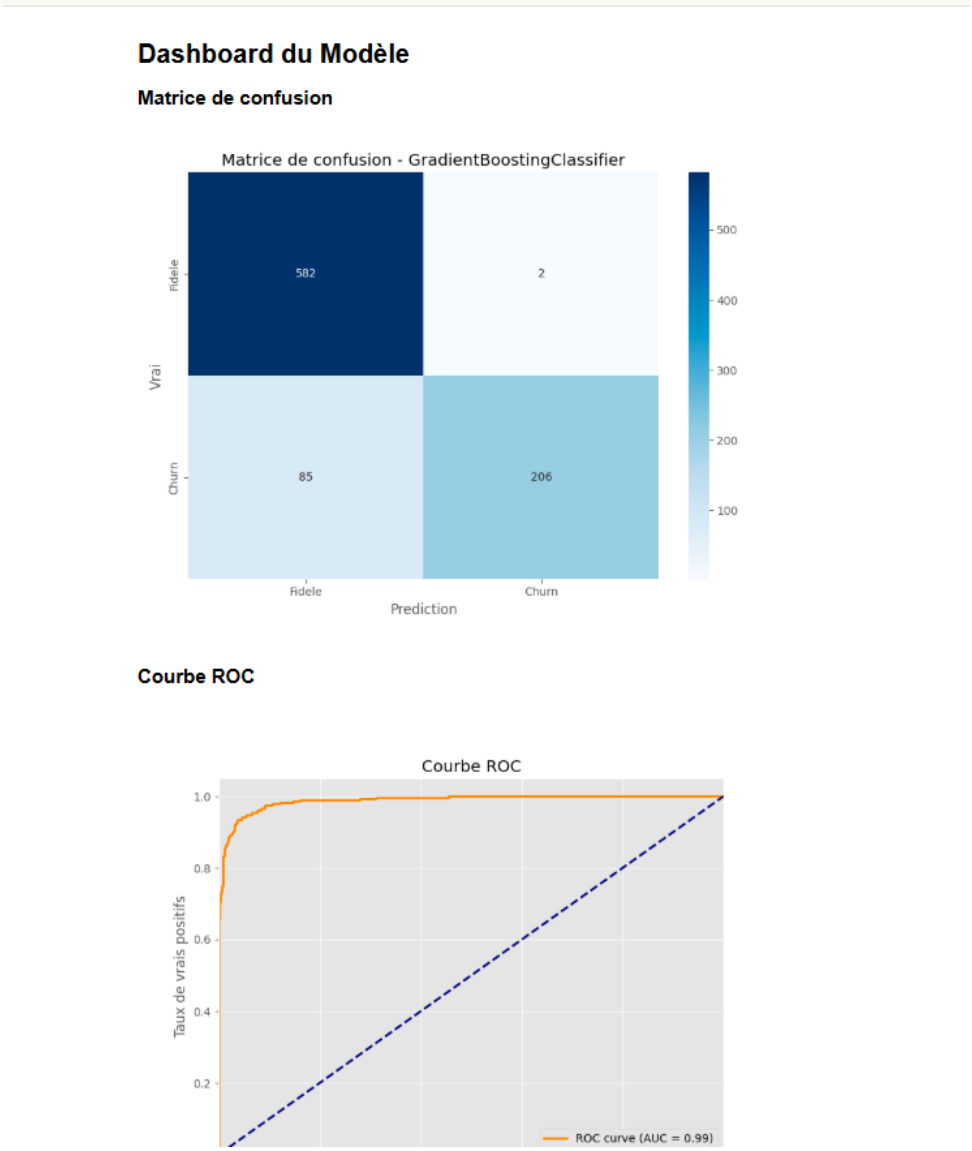

FIGURE 5.3 – Tableau de bord - Visualisation des performances du modèle

Explication : Le tableau de bord présente les graphiques générés lors de l'entraînement :

— Matrice de confusion
— Courbe ROC
— Variance expliquée par l'ACP
— Analyse des clusters

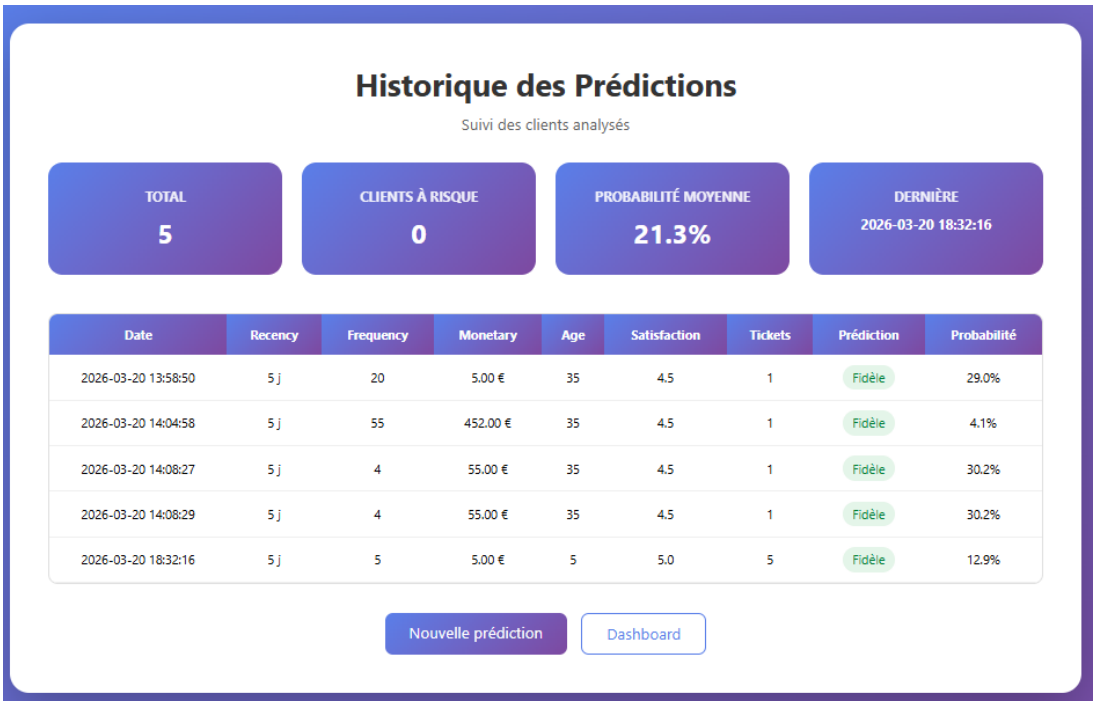

Date	Recency	Frequency	Monetary	Age	Satisfaction	Tickets	Prédiction	Probabilité
2026-03-20 13:58:50	5 j	20	5.00 €	35	4.5	1	Fidèle	29.0%
2026-03-20 14:04:58	5 j	55	452.00 €	35	4.5	1	Fidèle	4.1%
2026-03-20 14:08:27	5 j	4	55.00 €	35	4.5	1	Fidèle	30.2%
2026-03-20 14:08:29	5 j	4	55.00 €	35	4.5	1	Fidèle	30.2%
2026-03-20 18:32:16	5 j	5	5.00 €	5	5.0	5	Fidèle	12.9%

FIGURE 5.4 – Historique des prédictions effectuées

Explication : L'historique sauvegarde chaque prédiction avec la date, les données client et le résultat. Il permet de suivre l'évolution des prédictions et d'identifier les clients à risque.

5.1.3 Endpoints de l'API

- `http://127.0.0.1:5000/` : Formulaire de saisie (GET)
- `http://127.0.0.1:5000/predict` : Prédiction (POST)
- `http://127.0.0.1:5000/dashboard` : Tableau de bord (GET)
- `http://127.0.0.1:5000/history` : Historique (GET)

5.2 Recommandations Métier

5.2.1 Pour les Clients à Risque Élevé (Cluster 1)

Profil : Clients atypiques, tickets support élevés, comportement anormal, taux de churn 50%

- Analyser manuellement les 2 clients de ce cluster pour comprendre les causes du comportement atypique
- Contacter par téléphone via le service client dédié pour comprendre le mécontentement
- Offrir des réductions personnalisées de 20-30% sur la prochaine commande
- Proposer un suivi personnalisé pour rétablir la confiance

5.2.2 Pour les Clients Standards (Cluster 0)

Profil : Comportement d'achat normal, taux de churn 33.2%

Ce cluster regroupe la quasi-totalité des clients (3 495 clients). Il peut être subdivisé en sous-groupes selon les dépenses et la fréquence :

Clients à Risque (dépenses <500€, fréquence <2)

- Envoyer des newsletters ciblées sur les produits favoris
- Proposer des recommandations personnalisées par email
- Offrir la livraison gratuite sur la prochaine commande
- Réaliser des enquêtes de satisfaction flash (NPS)

Clients Fidèles (dépenses >1000€, fréquence >5)

- Programme VIP avec avantages exclusifs (accès anticipé, offres spéciales)
- Accès aux nouveautés en avant-première
- Programme de parrainage récompensé (crédit pour le parrain et le filleul)
- Service client prioritaire avec ligne dédiée

Clients Intermédiaires (dépenses 500-1000€, fréquence 2-5)

- Envoyer des offres personnalisées basées sur l'historique d'achat
- Proposer des produits complémentaires
- Offrir un code de réduction de 10% sur la prochaine commande

Conclusion

L'application web Flask est opérationnelle et permet une utilisation immédiate du modèle par l'équipe marketing. Les recommandations formulées, basées sur l'analyse des segments, offrent une feuille de route claire pour réduire le churn et fidéliser les clients.

Conclusion Générale

Ce projet avait pour ambition de développer une solution de prédiction du churn client pour une entreprise e-commerce spécialisée dans les cadeaux, en s'appuyant sur des techniques avancées de machine learning. L'objectif était de fournir un outil opérationnel permettant d'anticiper les départs et de mettre en place des actions de fidélisation ciblées.

L'analyse exploratoire a mis en évidence une distribution déséquilibrée des données (33.3% de churn) ainsi que la présence de valeurs aberrantes, notamment sur les colonnes SupportTickets et SatisfactionScore. Après un prétraitement rigoureux incluant l'imputation des valeurs manquantes, l'encodage des variables catégorielles et la standardisation, le jeu de données final comptait 6 166 features.

L'application de l'ACP a permis de réduire la dimensionnalité à 3 250 composantes tout en conservant 95% de la variance totale. Le clustering KMeans a identifié deux segments de clients : un cluster majoritaire de 3 495 clients présentant un taux de churn de 33.2%, et un cluster résiduel de 2 clients atypiques.

Le modèle Gradient Boosting optimisé par GridSearchCV atteint des performances remarquables avec une accuracy de 90.06% et un AUC-ROC de 0.99. Il se distingue par sa capacité à identifier parfaitement les clients fidèles (Recall=1.00) et sa grande précision dans la détection des churn (Précision=0.99). Une application web interactive a été développée avec Flask, offrant une interface intuitive pour l'équipe marketing.

Ce travail confirme le potentiel du machine learning dans l'anticipation du churn client. La solution développée constitue une base solide pour une mise en production et ouvre des perspectives d'amélioration, notamment l'intégration avec le CRM existant et l'exploration de modèles plus avancés.

Chapitre A Guide d'Installation Complet

```
# 1. Cloner le depot
git clone https://github.com/abidirymeh/ProjetML.git
cd ProjetML

# 2. Creer l'environnement virtuel
python -m venv venv

# 3. Activer l'environnement
# Windows:
venv\Scripts\activate
# Linux/Mac:
source venv/bin/activate

# 4. Installer les dependances
pip install -r requirements.txt

# 5. Executer le preprocessing
python src/preprocessing.py

# 6. Entrainer le modele
python src/train_model.py

# 7. Lancer l'application
cd app
python app.py

# 8. Acceder a l'application
# Ouvrir http://127.0.0.1:5000
```

Listing A.1 – Installation et exécution du projet

Chapitre B Dépendances Complètes

```
pandas==2.2.0
numpy==1.26.3
scikit-learn==1.5.0
matplotlib==3.8.2
seaborn==0.13.2
flask==3.0.2
joblib==1.3.2
jupyter==1.0.0
scipy==1.15.3
```

Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce projet.

En premier lieu, je remercie chaleureusement ma **famille** pour leur soutien indéfectible, leur patience et leurs encouragements tout au long de cette formation.

Je remercie également **Mme Fadoua Drira**, ma formatrice, pour son accompagnement exceptionnel, sa disponibilité et ses précieux conseils qui ont été déterminants dans la réussite de ce travail.

Mes remerciements s'adressent aussi à l'**équipe pédagogique** pour la qualité de l'enseignement dispensé.